Attention Is All You Need

Transformer 原论文学习汇报

Vaswani 等 · NIPS 2017

李卓凡 · 2026 年 10 月 12 日

序列建模中的顺序计算

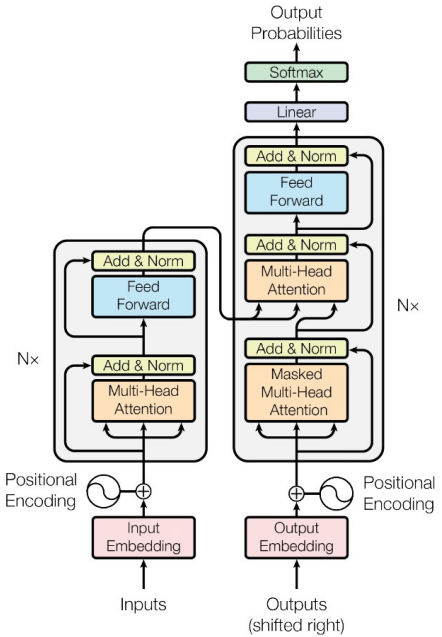
研究问题

怎样减少循环网络沿序列逐步计算的限制，同时学习远距离依赖？

- RNN 按位置更新隐藏状态，单个训练样本内难以并行。
- Transformer 用注意力连接不同位置，保留编码器—解码器框架。
- 这里的并行主要指训练计算，推理仍逐个生成输出 token 。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 2 页

编码器与解码器架构



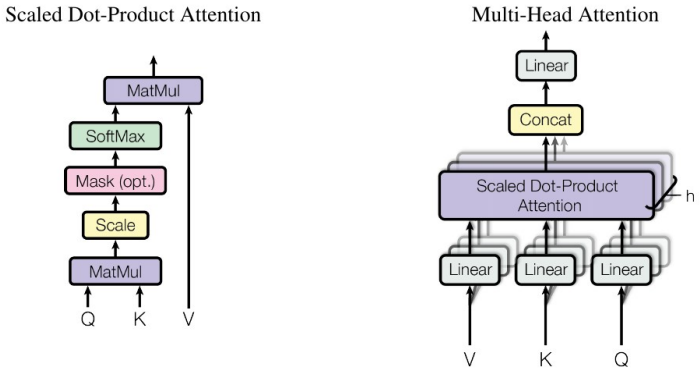
- 编码器与解码器各堆叠 6 层。
- 编码器层：自注意力、逐位置前馈网络。
- 解码器增加掩码自注意力及对编码器输出的交叉注意力。

原论文采用残差后层归一化：

$$\text{LayerNorm}(x + \text{Sublayer}(x))$$

来源： Vaswani 等， Attention Is All You Need ， PDF 第 3 页， Figure 1

缩放点积注意力



$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$$

- Q 与 K 点积得到匹配分数。
- 缩放后用 softmax 归一化。
- 权重对 V 加权求和。

图左为单个注意力计算，图右为多个头的并行计算。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 4 页， Figure 2

多头注意力的维度

同一输入通过不同线性投影，进入多个注意力头。

$\text{MultiHead} = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)W^O$

Base： d_model = 512 ， h = 8 ， $d_k = d_v = 64$

- 每个头在不同的表示子空间计算注意力。
- 拼接各头后再投影，输出仍为 512 维。
- 这是原论文 Base 配置，不是本章 Qwen3 的 16 个 Query 头。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 4–5 页， §3.2.2

三种注意力的输入与可见范围

注意力位置	Q 来自哪里	K / V 来自哪里	可见范围
编码器自注意力	编码器当前表示	同一输入序列	全部输入位置
解码器自注意力	解码器当前表示	同一输出序列	已知输出位置
编码器—解码器	解码器表示	编码器输出	全部输入位置

解码器掩码挡住未来位置；交叉注意力读取编码器已经得到的输入表示。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 5 页， §3.2.3

位置信息与前馈网络

位置编码

输入嵌入与同维度的位置编码相加。

PE(pos, 2i) = sin(pos / 10000^(2i/d_model))

PE(pos, 2i+1) = cos(pos / 10000^(2i/d_model))

逐位置前馈网络

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

Base： 512 维输入，中间层 2048 维，输出 512 维。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 5–6 页， §3.3 、 §3.5

自注意力的计算代价

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

n 为序列长度， d 为表示维度。论文指出 n < d 时，自注意力计算上有优势。

- 全局自注意力：每层 $O(n^2d)$ 。
- 顺序操作数和最长路径可为 O(1) 。
- 序列很长时，二次复杂度仍是代价。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 6–7 页， Table 1

数据与训练设置

- WMT 2014 英德约 450 万句对，英法约 3600 万句对。
- 8 张 NVIDIA P100： Base 约 12 小时， Big 约 3.5 天。
- Adam： $\beta_1=0.9$ ， $\beta_2=0.98$ ， $\varepsilon=10^{-9}$ 。
- 前 4000 步学习率预热，之后按步数的逆平方根下降。
- Base 使用 dropout 0.1 ，标签平滑 0.1 。

以上为论文训练记录，本次未重新训练 Transformer 。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 7–8 页， §5

机器翻译结果

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	**$3.3 \cdot 10^{18}$**	
Transformer (big)	**28.4**	**41.8**	$2.3 \cdot 10^{19}$	

28.4

Big · 英德 BLEU

41.8

Big · 英法 BLEU，按表 2

表 2 与摘要给出英法 41.8，正文 §6.1 写 41.0；本页保留这处原文不一致。

来源：Vaswani 等，Attention Is All You Need，PDF 第 8 页，Table 2、§6.1

组件变化与开发集表现

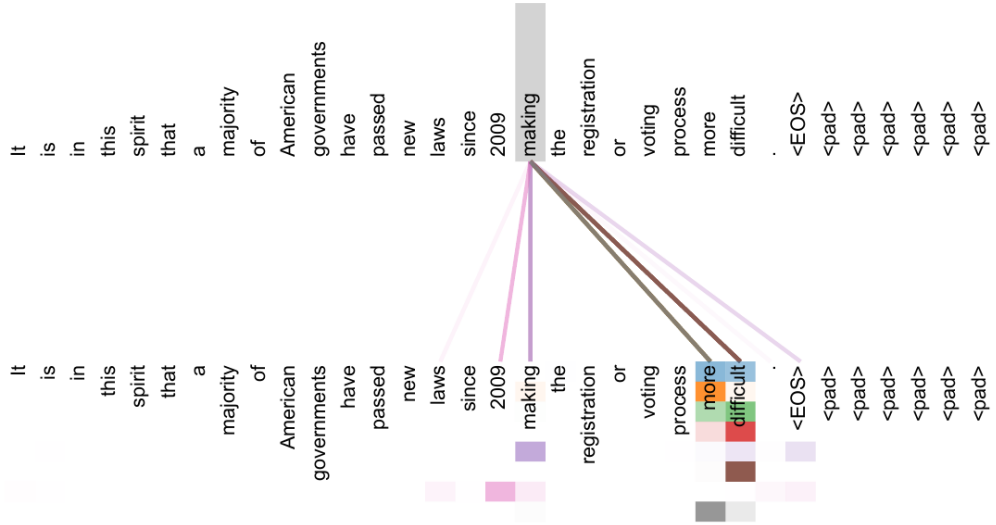
配置，其他项沿用 Base	BLEU(dev)
Base ， 8 头	25.8
1 头	24.9
4 头	25.5
16 头	25.8
32 头	25.4
可学习位置嵌入	25.7

- 单头 24.9 ，比 Base 低 0.9 BLEU 。
- 头数增加不保证持续提高。
- 可学习位置嵌入与正弦方案接近。

这些是 newstest2013 开发集结果，不与上一页测试集分数直接比较。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 9 页， Table 3

注意力中的远距离依赖



远距离依赖

- 只展示 making 位置。
- 不同颜色代表不同头。
- 编码器第 5 层，共 6 层。

原文示例： making … more difficult 。注意力图提示关联，不能单凭权重判断因果重要性。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 13 页， Figure 3

英语成分句法分析

Transformer 训练条件	WSJ 23 F1
仅 WSJ ，有监督	91.3
半监督	92.7

4 层 Transformer

d_model = 1024

WSJ：约 4 万句。

半监督：约 1700 万句。

评测为 WSJ Section 23 的 F1 。不同训练条件分开比较， 92.7 不是所有表列方法的最高分。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 9–10 页， Table 4

贡献与适用边界

主要贡献

- 用多头注意力组织编码器—解码器，减少循环计算。
- 在论文机器翻译任务上取得较高 BLEU ，并报告较低训练成本。

需要保留的边界

- 全局注意力随序列长度呈二次复杂度增长。
- 训练并行不代表自回归推理完全并行。
- 结果属于论文任务与训练设置，不能直接外推到所有任务。

来源： Vaswani 等， Attention Is All You Need ， PDF 第 2 、 6–10 页， §7